

Métodos Iterativos para Otimização Sem Restrições

Fernanda Costa

Departamento de Matemática
Universidade do Minho

Outline

- 1 Métodos iterativos para otimização sem restrições
- 2 Critério de paragem
- 3 Métodos de procura unidirecional (geral)
- 4 Comprimento do passo
- 5 Convergência dos métodos de procura unidirecional
- 6 Taxas de convergência
- 7 Anexo
 - Resolução do exemplo da página 14
 - Demonstração do Teorema (Zoutendijk)

Métodos iterativos para otimização sem restrições

Em geral, não se consegue resolver

$$\underset{w \in \mathbb{R}^d}{\text{minimizar}} F(w)$$

analiticamente, e recorre-se a métodos iterativos.

Métodos iterativos para Otimização

- Começam a partir de um dado ponto inicial $w^{(0)} \in \mathbb{R}^d$ (aproximação inicial à solução);
- Dado $w^{(k)}$, calculam um novo ponto (melhor) $w^{(k+1)}$, e este processo repete-se ($k = 0, 1, 2, \dots$).
- Geram uma sucessão de pontos $w^{(1)}, w^{(2)}, \dots, w^{(k)}, \dots$ que converge para a solução ótima w^* .
- O método *termina* quando deixa de ser possível obter progresso significativo ou quando a solução ótima w^* é aproximada com precisão previamente fixada.

Critério de paragem

- Ao utilizar um algoritmo de otimização, procura-se um ponto $w^{(k)}$ onde

$$\nabla F(w^{(k)}) = \mathbf{0}.$$

Na prática, devido à aritmética de precisão finita, adota-se como critério de paragem

$$\|\nabla F(w^{(k)})\|_\infty < \varepsilon, \quad (1)$$

com $\varepsilon > 0$ suficientemente pequeno.

- A segunda condição de otimalidade (Hessiana semidefinida positiva) não é, em geral, utilizada.

Assim, o algoritmo apenas garante um ponto estacionário (ponto máximo, mínimo ou sela).

- Contudo, como os algoritmos que vamos estudar geram direções de descida, espera-se, na prática, convergência para um mínimo local.

- Num algoritmo prático, utilizam-se outras condições para além da condição (1). Por vezes, a função pode apresentar problemas numéricos ou ser ilimitada inferiormente, que impedem a verificação da condição (1).
- Para evitar que o algoritmo execute indefinidamente, é habitual impor um *número máximo* ao *número de iterações*, K_{max} , ou ao *número de avaliações da função*, NF_{max} , ou ao *tempo de execução*, T_{max} .
- Além disso, para detetar situações em que o algoritmo não está a fazer progressos significativos, podem definir-se condições adicionais baseadas na proximidade entre dois pontos consecutivos e na variação do valor da função objetivo, em termos absoluto ou relativo:

$$\|w^{(k)} - w^{(k-1)}\| \leq \varepsilon_2 \quad \text{ou} \quad \frac{\|w^{(k)} - w^{(k-1)}\|_\infty}{\|w^{(k)}\|_\infty} \leq \varepsilon_2$$

$$|F(w^{(k)}) - F(w^{(k-1)})| \quad \text{ou} \quad \frac{|F(w^{(k)}) - F(w^{(k-1)})|}{|F(w^{(k)})|} \leq \varepsilon_3$$

Critérios de paragem em algoritmos para otimização sem restrições.

Critério (proposto por Wolfe). Parar o algoritmo se:

1 $\left\| \nabla F(w^{(k)}) \right\|_{\infty} \leq \varepsilon_1$ e (medida de estacionaridade)

2 $\frac{\left\| w^{(k)} - w^{(k-1)} \right\|_{\infty}}{\|w^{(k)}\|_{\infty}} \leq \varepsilon_2$ e

3 $\frac{|F(w^{(k)}) - F(w^{(k-1)})|}{|F(w^{(k)})|} \leq \varepsilon_3$

onde $\varepsilon_1 > 0, \varepsilon_2 > 0, \varepsilon_3 > 0$ são pequenas tolerâncias próximas de zero. Na prática, $\varepsilon_1 = 10^{-6}$ e $\varepsilon_2 = \varepsilon_3 = 10^{-6}$.

Critério (proposto por Gill e Murray): Terminar o algoritmo se:

① $\|\nabla F(w^{(k)})\|_{\infty} \leq \varepsilon^{\frac{1}{3}} \left(1 + |F(w^{(k)})|\right)$ e

② $\|w^{(k)} - w^{(k-1)}\|_{\infty} \leq \varepsilon \left(1 + \|w^{(k)}\|_{\infty}\right)$ e

③ $|F(w^{(k)}) - F(w^{(k-1)})| \leq \varepsilon^2 \left(1 + |F(w^{(k)})|\right)$

onde $\varepsilon > 0$ é uma pequena tolerância próxima de zero.

Observações:

- Este critério é de aplicação mais geral. Pode ser aplicado a problemas em que a solução ótima é o vetor nulo ou o valor ótimo da função objetivo é zero.

Métodos de procura unidirecional (geral)

Os métodos de procura unidirecional tem, em cada iteração, três passos principais:

Estrutura geral

- ① Escolher uma direção de procura $s^{(k)}$ a partir do ponto atual $w^{(k)}$;
- ② Calcular a distância a percorrer nessa direção, η_k , realizando uma procura unidirecional;
- ③ Mover para o novo ponto: $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$.

O bom desempenho de um método de procura unidirecional depende das escolhas da *direção de procura* $s^{(k)}$ e do *comprimento do passo* η_k .

De preferência $s^{(k)}$ é uma *direção de descida*, isto é, $s^{(k)T} \nabla F(w^{(k)}) < 0$, o que garante que a função F decresce ao longo dessa direção.

O *método de procura unidirecional (geral)* é definido pelo seguinte algoritmo iterativo.

Algoritmo 1: Método de procura unidirecional (geral)

- ➊ Entrada: F , $w^{(0)}$, tolerância $\varepsilon > 0$
 - ➋ Fazer $k = 0$
 - ➌ Enquanto ($\|\nabla F(w^{(k)})\|_\infty > \varepsilon$) fazer
 - ➍ Calcular uma direção de procura $s^{(k)}$ tal que $s^{(k)T} \nabla F(w^{(k)}) < 0$
 - ➎ Calcular o comprimento do passo η_k tal que
$$F(w^{(k)} + \eta_k s^{(k)}) < F(w^{(k)})$$
 - ➏ Fazer $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$
 - ➐ Fazer $k = k + 1$
 - ➑ Fim enquanto
 - ➒ Saída: $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)
-

Existem vários métodos para escolher a *direção de procura* $s^{(k)}$. Na aula seguinte, estudaremos os seguintes:

- Método de descida máxima (ou Método do gradiente).
- Método de Newton.
- Métodos quasi-Newton.

Como escolher o *comprimento do passo* η_k ?

- A escolha de η_k deverá conduzir a um decréscimo substancial de F e ser pouco dispendiosa.

Comprimento do passo

A procura exata do η_k :

$$\underset{\eta \in \mathbb{R}_0^+}{\text{minimizar}} \phi(\eta) = F(w^{(k)} + \eta s^{(k)})$$


é impraticável, devido ao elevado custo computacional e, em geral, não é necessária. Na prática, recorre-se a técnicas de procura não exata.

Vamos tentar decrescer



$$\phi(\eta) = F(w^{(k)} + \eta s^{(k)}), \quad \eta \geq 0$$

a partir de $\eta = 0$.

Contudo, minimizar $\phi(\eta)$ pode ser difícil.



Pretende-se testar um número finito (pequeno) de valores para η , por ex.,




Uma condição natural a impor ao parâmetro η_k é a **condição de decréscimo simples**:

$$F(w^{(k)} + \eta_k s^{(k)}) < F(w^{(k)}).$$

Mas, esta condição, por si só, não garante a convergência para um ponto estacionário, podendo o método convergir antes de o atingir!

Exemplo: Considere $F : \mathbb{R} \rightarrow \mathbb{R}$ dada por $F(w) = w^2$, que tem um minimizante global em $w^* = 0$. (a) Utilize o algoritmo de descida geral com $s^{(k)} = -1$, $\eta_k = \frac{1}{2^{k+1}}$ e ponto inicial dado por $w^{(0)} = 2$. Desenhe os iterados gerados pelo algoritmo, definidos por $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$, usando o MatLab. O que pode concluir? (b) Resolva a alínea anterior com com $s^{(k)} = (-1)^{k+1}$ e $\eta_k = 2 + \frac{3}{2^{k+1}}$.

Solução:




(a) passos muito curtos

$$w^{(k)} = 1 + \frac{1}{2^k}$$

$$w^{(k)} \rightarrow 1$$

1 não é minimizante de F



(b) passos muito longos

$$w^{(k)} = 1 + \frac{1}{2^k} \text{ (k ímpar)}; w^{(k)} = -1 - \frac{1}{2^k} \text{ (k par)}$$

$$w^{(k)} \rightarrow -1 \text{ (k par)}$$

$$w^{(k)} \rightarrow 1 \text{ (k ímpar)}$$

-1 e 1 não são minimizantes de F

Em ambos os casos, o algoritmo satisfaz a condição de decréscimo simples,

$(F(w^{(k+1)}) < F(w^{(k)}) \text{ para } k = 0, 1, \dots)$, mas não converge para o minimizante!

Para simplificar a exposição da procura unidirecional, vamos considerar a função de 1 variável

$$\phi(\eta) = F(w^{(k)} + \eta s^{(k)}) \quad (2)$$

onde $\eta = 0$ corresponde ao início da procura unidirecional ($w^{(k)}$), e portanto $\phi(0) = F(w^{(k)})$.

Pela regra da cadeia, usando $w = w^{(k)} + \eta s^{(k)}$, a derivada de ϕ é

$$\phi'(\eta) = \frac{\partial(F(w))}{\partial\eta} = \sum_{i=1}^d \frac{\partial F}{\partial w_i} \frac{dw_i}{d\eta} \iff$$

$$\phi'(\eta) = \nabla F(w^{(k)} + \eta s^{(k)})^T s^{(k)}$$

que é a derivada direcional de F ao longo da direção de procura $s^{(k)}$. O declive no início de cada procura unidirecional é

$$\phi'(0) = \nabla F(w^{(k)})^T s^{(k)}.$$

Como $s^{(k)}$ tem de ser uma direção de descida, $\phi'(0) < 0$ é sempre negativo!

Condições de Wolfe

As condições de Wolfe englobam a **condição de decréscimo suficiente (CDS)** e a **condição de curvatura (CC)**.


A CDS, também designada por **condição de Armijo**, é dada pela desigualdade:

$$\begin{aligned} F(w^{(k)} + \eta s^{(k)}) - F(w^{(k)}) &\leq c_1 \eta \underbrace{\nabla F(w^{(k)})^T s^{(k)}}_{\phi'(0)} \iff \\ \underbrace{F(w^{(k)} + \eta s^{(k)})}_{\phi(\eta)} &\leq \underbrace{F(w^{(k)}) + c_1 \eta \nabla F(w^{(k)})^T s^{(k)}}_{l(\eta)} \end{aligned} \quad (3)$$

onde $0 < c_1 < 1$ é uma constante. A quantidade $\eta\phi'(0)$ representa o decréscimo esperado da função F . O multiplicador c_1 diz que (3) será satisfeita desde que se obtenha pelo menos uma pequena fração do decréscimo esperado.

Em (3), $l(\eta)$ é uma função linear de declive negativo $c_1\eta\phi'(0)$. Como $c_1 \in (0, 1)$, a reta $l(\eta)$ situa-se acima do gráfico de $\phi(\eta)$ para valores de η pequenos.

A CDS diz que η é aceitável se $\phi(\eta) \leq l(\eta)$. Os intervalos onde CDS é satisfeita são apresentados na Figura. Na prática, c_1 é escolhido bastante pequeno, $c_1 = 10^{-4}$.



Condição de decréscimo suficiente

A CDS, por si só, não é suficiente para garantir que o algoritmo faça um progresso razoável porque, como podemos ver da Figura, pode ser satisfeita por comprimentos de passo muito pequenos!

Para excluir passos demasiado curtos, introduz-se uma segunda condição, a CC, que exige que η_k satisfaça:

$$\underbrace{\nabla F(w^{(k)} + \eta_k s^{(k)})^T s^{(k)}}_{\phi'(\eta_k)} \geq c_2 \underbrace{\nabla F^T(w^{(k)}) s^{(k)}}_{\phi'(0)} \quad (4)$$


com $c_2 \in (c_1, 1)$, onde c_1 é a constante de (3).

A CC rejeita declives demasiados negativos (o declive em η_k , $\phi'(\eta_k)$, tem de ser maior c_2 vezes o declive inicial $\phi'(0)$). Isto faz sentido porque, se o declive $\phi'(\eta)$ é fortemente negativo, isso indica que ainda é possível reduzir significativamente o valor de F avançando mais na direção $s^{(k)}$.

Por outro lado, se $\phi'(\eta)$ for apenas ligeiramente negativo, ou mesmo positivo, isso indica que não é razoável esperar uma redução muito maior nessa direção. Portanto, faz sentido terminar a procura.

Na prática, $c_2 = 0.9$ quando a direção de procura $s^{(k)}$ é dada pelo método de Newton ou pelo método quasi-Newton.

Os intervalos onde CC é satisfeita são apresentados na Figura.



Condição de curvatura

Lema

Seja $F : \mathbb{R}^d \rightarrow \mathbb{R}$ continuamente diferenciável. Seja $s^{(k)}$ uma direcção de descida em $w^{(k)}$ e F limitada inferiormente ao longo da semi-recta $\{w^{(k)} + \eta s^{(k)} : \eta > 0\}$. Então, se $0 < c_1 < c_2 < 1$, existem intervalos de comprimentos de passo satisfazendo as condições de Wolfe, CDS (3) e CC (4).

Demonstração: $\phi(\eta) = F(w^{(k)} + \eta s^{(k)})$ é limitada inferiormente.

Uma vez que $0 < c_1 < 1$, $I(\eta) = F(w^{(k)}) + c_1 \eta \nabla F(w^{(k)})^T s^{(k)}$ tende para $-\infty$ quando $\eta \rightarrow +\infty$.

Por isso intersecta ϕ pelo menos uma vez.

Seja η' o menor valor de η dessa intersecção, assim

$$F(w^{(k)} + \eta' s^{(k)}) = F(w^{(k)}) + c_1 \eta' \nabla F(w^{(k)})^T s^{(k)}$$

Logo a CDS é válida $\forall \eta < \eta'$.

Pelo teorema do valor médio

$$\exists \eta'' \in (0, \eta') : F(w^{(k)} + \eta' s^{(k)}) - F(w^{(k)}) = \eta' \nabla F(w^{(k)} + \eta'' s^{(k)})^T s^{(k)}$$

Tendo em conta as duas últimas equações, vem


$$\nabla F(w^{(k)} + \eta'' s^{(k)})^T s^{(k)} = c_1 \nabla F(w^{(k)})^T s^{(k)}$$

Uma vez que $c_1 < c_2$ e $\nabla F(w^{(k)})^T s^{(k)} < 0$, vem

$$\nabla F(w^{(k)} + \eta'' s^{(k)})^T s^{(k)} = c_1 \nabla F(w^{(k)})^T s^{(k)} > c_2 \nabla F(w^{(k)})^T s^{(k)}$$

Assim, η'' satisfaz as condições de Wolfe e pelo facto de ∇F ser contínuo, existe um intervalo em torno de η'' onde as condições de Wolfe são satisfeitas. \square

Os intervalos onde as condições de Wolfe, CDS e CC, são satisfeitas são apresentados na Figura.



Intervalos de comprimentos de passo satisfazendo as condições de Wolfe

Decréscimo Suficiente e Backtracking

Como referido a CDS (3), por si só, não garante progresso adequado ao longo da direção de procura.

Contudo, se o algoritmo de procura unidirecional selecionar os comprimentos de passo candidatos de forma apropriada, recorrendo à estratégia de **backtracking**, podemos dispensar a CC (4) e usar apenas a CDS (3).

Algoritmo: Condição de Armijo com backtracking

- ① **Entrada:** $\eta_0 > 0$, $\rho \in (0, 1)$, $c \in (0, 1)$, F , $\nabla F(w^{(k)})$, $w^{(k)}$, $s^{(k)}$
 - ② Fazer $\eta = \eta_0$
 - ③ Enquanto $F(w^{(k)} + \eta s^{(k)}) > F(w^{(k)}) + c\eta \nabla F(w^{(k)})^T s^{(k)}$ fazer
 - ④ Fazer $\eta = \rho \eta$
 - ⑤ Fim enquanto
 - ⑥ **Saída:** $\eta_k \leftarrow \eta$ (valor para η_k)
-

Notas (estratégia de *backtracking*):

- Inicia-se com um comprimento de passo relativamente grande e este é sucessivamente reduzido, multiplicando por um fator $\rho < 1$, até que a CDS seja satisfeita.
- Trata-se de uma heurística simples para garantir a verificação da CDS.
- Na prática, o comprimento de passo inicial é frequentemente escolhido como $\eta_0 = 1$ quando a direção de procura $s^{(k)}$ é obtida pelo método de Newton ou por métodos quasi-Newton. Noutros métodos, como o método do gradiente, podem ser usados outros valores iniciais.
- O procedimento termina sempre, pois a CDS é satisfeita para η_k suficientemente pequeno.
- Na prática, o fator de contração é geralmente fixo, sendo habitual a escolha $\rho = \frac{1}{2}$.

Convergência dos métodos de procura unidirecional

- Diz-se que um método tem *convergência de primeira ordem* se a sucessão de iterados $\{w^{(k)}\}$ gerada pelo método converge para um *ponto estacionário*.
 - ▶ Usa-se o termo *convergência global* se o método converge para um ponto estacionário qualquer que seja o ponto inicial $w^{(0)}$.
 - ▶ Usa-se o termo *convergência local* se o método converge para um ponto estacionário apenas se o ponto inicial $w^{(0)}$ está suficientemente próximo de uma solução w^* .

Convergência dos métodos de procura unidirecional

- Para garantir convergência global, é necessário escolher bem tanto os comprimentos de passo η_k quanto as direções de procura $s^{(k)}$.
- Apresentamos um teorema que estabelece condições sobre a direção de procura $s^{(k)}$ para garantir convergência global, baseado no ângulo θ_k entre $s^{(k)}$ e a direção de máxima descida $-\nabla F(w^{(k)})$:

$$\cos \theta_k = \frac{-\nabla F(w^{(k)})^\top s^{(k)}}{\|\nabla F(w^{(k)})\| \|s^{(k)}\|} \quad (5)$$

e assumindo que η_k satisfaz as condições de Wolfe.

- Este Teorema é importante: por exemplo, mostra que o método da descida máxima (método do gradiente) é *globalmente convergente*; para outros métodos, descreve até que ponto $s^{(k)}$ pode desviar-se da direção de máxima $-\nabla f(w^{(k)})$ e ainda assim gerar um algoritmo *globalmente convergente*.

Teorema (Zoutendijk)

Considere-se um método iterativo $w^{(k+1)} = w^{(k)} + \eta s^{(k)}$, em que $s^{(k)}$ é uma direção de descida e η_k satisfaz as condições de Wolfe.

Suponhamos que F é limitada inferiormente em \mathbb{R}^d e que é continuamente diferenciável num conjunto aberto \mathcal{N} contendo o conjunto de nível

$$\mathcal{L}(w^{(0)}) = \{ w : F(w) \leq F(w^{(0)}) \},$$

onde $w^{(0)}$ é o ponto inicial da iteração.

Suponhamos, ainda, que ∇F é contínua à Lipschitz (com constante $L > 0$) em \mathcal{N} :

$$\|\nabla F(w) - \nabla F(\tilde{w})\| \leq L\|w - \tilde{w}\|.$$

Então, tem-se

$$\sum_{k=0}^{+\infty} \cos^2 \theta_k \|\nabla F(w^{(k)})\|^2 < +\infty \quad (\text{condição de Zoutendijk}).$$

Do teorema de Zoutendijk, resulta que

$$\cos^2 \theta_k \|\nabla F(w^{(k)})\|^2 \rightarrow 0.$$

Se existir uma constante $\varepsilon > 0$ tal que

$$\cos \theta_k \geq \varepsilon > 0 \quad \text{para todo } k,$$

então

$$\cos^2 \theta_k \|\nabla F(w^{(k)})\|^2 \rightarrow 0 \iff \|\nabla F(w^{(k)})\| \rightarrow 0.$$

Por outras palavras, podemos garantir que as normas do gradiente $\|\nabla F(w^{(k)})\|$ convergem para zero, desde que as direções de procura $s^{(k)}$ nunca se tornem quase ortogonais ao vetor gradiente $\nabla F(w^{(k)})$.

Exemplos:

- Método de descida máxima:

$$s^{(k)} = -\nabla f(w^{(k)}) \Rightarrow \cos \theta_k = 1 > 0 \quad \forall k \Rightarrow \text{convergência global.}$$

Método simples e intuitivo, mas pode ser lento.

- Métodos do tipo Newton:

$$s^{(k)} = -B_k^{-1} \nabla f(w^{(k)}),$$

com B_k uma matriz simétrica e definida positiva (SPD) e com número de condição limitado, $\text{cond}(B_k) = \|B_k\| \|B_k^{-1}\| \leq M$, então:

$$\cos \theta_k \geq \frac{1}{M} > 0 \quad \forall k \Rightarrow \text{convergência global.}$$

Se B_k são definidas positivas, com número de condição limitado, e η_k satisfaz as condições de Wolfe, então o método é *globalmente convergente*.

Isto inclui, o método de descida máxima, alguns métodos de Newton e quasi-Newton.

Taxas de convergência

FALTA FAZER!

ANEXO

Resolução matemática do exemplo da página 14:

(a): Matematicamente temos $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)} = w^{(k)} - \eta_k$, para $k = 0, 1, 2, \dots$:

$$w^{(1)} = w^{(0)} - \eta_0$$

$$w^{(2)} = w^{(1)} - \eta_1 = w^{(0)} - \eta_0 - \eta_1$$

$\dots = \dots$

$$w^{(k+1)} = w^{(k)} - \eta_k = w^{(0)} - \sum_{i=0}^k \eta_i.$$

Portanto,

$$\begin{aligned} w^{(k+1)} &= 2 - \sum_{i=0}^k \frac{1}{2^{i+1}} = 2 - \frac{1}{2} \sum_{i=0}^k \frac{1}{2^i} = 2 - \frac{1}{2} \left(\frac{1 - (\frac{1}{2})^{k+1}}{1 - \frac{1}{2}} \right) = 2 - \left(1 - \left(\frac{1}{2} \right)^{k+1} \right) \\ &= 1 + \left(\frac{1}{2} \right)^{k+1} \end{aligned}$$

Observar que $0 < w^{(k+1)} < w^{(k)}$ e F é crescente para $w > 0$. Portanto, é verificada a condição de decréscimo simples:

$$F(w^{(k+1)}) < F(w^{(k)}), \quad \text{para } k = 0, 1, \dots$$

Temos, para $k \rightarrow \infty$, $w^{(k)} = 1 + \left(\frac{1}{2}\right)^k \rightarrow 1$ e $F(w^{(k)}) \rightarrow 1$. Mas o minimizante é 0, portanto o 1 não é ponto estacionário.

(b): Matematicamente temos $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)} = w^{(k)} + (-1)^{k+1} \eta_k$, para $k = 0, 1, 2, \dots$:

$$w^{(1)} = w^{(0)} - \eta_0$$

$$w^{(2)} = w^{(1)} + \eta_1 = w^{(0)} - \eta_0 + \eta_1$$

$\dots = \dots$

$$w^{(k+1)} = w^{(k)} + (-1)^{k+1} \eta_k = w^{(0)} + \sum_{i=0}^k (-1)^{i+1} \eta_i.$$

Portanto,

$$\begin{aligned} w^{(k+1)} &= 2 + \sum_{i=0}^k (-1)^{i+1} \left(2 + \frac{3}{2^{i+1}} \right) = 2 + 2 \sum_{i=0}^k (-1)^{i+1} + 3 \sum_{i=0}^k \left(\frac{-1}{2} \right)^{i+1} \\ &= 2 + 2 \begin{cases} -1, & k \text{ par} \\ 0, & k \text{ ímpar} \end{cases} + 3 \left(-\frac{1}{2} \frac{1 - (-\frac{1}{2})^{k+1}}{1 + \frac{1}{2}} \right) \\ &= 2 + \begin{cases} -2, & k \text{ par} \\ 0, & k \text{ ímpar} \end{cases} + 3 \left(-\frac{1}{3} \left(1 - \left(-\frac{1}{2} \right)^{k+1} \right) \right) \\ &= 2 + \begin{cases} -2, & k \text{ par} \\ 0, & k \text{ ímpar} \end{cases} + \left(-1 + \left(-\frac{1}{2} \right)^{k+1} \right) \\ &= 2 + \begin{cases} -3 - \left(\frac{1}{2} \right)^{k+1}, & k \text{ par,} \\ -1 + \left(\frac{1}{2} \right)^{k+1}, & k \text{ ímpar.} \end{cases} = \begin{cases} -1 - \left(\frac{1}{2} \right)^{k+1}, & k \text{ par,} \\ 1 + \left(\frac{1}{2} \right)^{k+1}, & k \text{ ímpar.} \end{cases} \end{aligned}$$

Portanto temos, para $k \rightarrow \infty$, $w^{(k)} \rightarrow -1$ se k par; $w^{(k)} \rightarrow 1$ se k ímpar. E $F(w^{(k)}) \rightarrow 1$, mas o minimizante é 0, portanto o 1 e -1 não são pontos estacionários.

Demonstração do Teorema (Zoutendijk):

Pela condição de decréscimo suficiente (CDS), tem-se

$$F(w^{(k+1)}) \leq F(w^{(k)}) + c_1 \eta_k \nabla F(w^{(k)})^\top s^{(k)}.$$

Necessitamos de um limite inferior para η_k . Pela condição de curvatura (CC),

$$\nabla F(w^{(k+1)})^\top s^{(k)} \geq c_2 \nabla F(w^{(k)})^\top s^{(k)}.$$

Logo, subtraindo $\nabla F(w^{(k)})^\top s^{(k)}$ a ambos os membros,

$$(\nabla F(w^{(k+1)}) - \nabla F(w^{(k)}))^\top s^{(k)} \geq (c_2 - 1) \nabla F(w^{(k)})^\top s^{(k)}.$$

Como ∇F é Lipschitz contínua com constante L , obtemos

$$\|(\nabla F(w^{(k+1)}) - \nabla F(w^{(k)}))^\top s^{(k)}\| \leq L \eta_k \|s^{(k)}\|^2.$$

Assim,

$$(c_2 - 1) \nabla F(w^{(k)})^\top s^{(k)} \leq L \eta_k \|s^{(k)}\|^2,$$

ou, equivalentemente,

$$\eta_k \geq \frac{c_2 - 1}{L} \frac{\nabla F(w^{(k)})^\top s^{(k)}}{\|s^{(k)}\|^2}.$$

Temos, pela CDS,

$$F(w^{(k+1)}) \leq F(w^{(k)}) + c_1 \eta_k \nabla F(w^{(k)})^\top s^{(k)},$$

e, substituindo este limite em CDS, obtemos

$$F(w^{(k+1)}) \leq F(w^{(k)}) - c_1 \frac{1 - c_2}{L} \frac{(\nabla F(w^{(k)})^\top s^{(k)})^2}{\|s^{(k)}\|^2}.$$

Definindo

$$c = c_1 \frac{1 - c_2}{L} > 0,$$

e usando a relação com o ângulo θ_k entre $s^{(k)}$ e $-\nabla F(w^{(k)})$:

$$\cos \theta_k = \frac{-\nabla F(w^{(k)})^\top s^{(k)}}{\|\nabla F(w^{(k)})\| \|s^{(k)}\|} \implies -\nabla F(w^{(k)})^\top s^{(k)} = \cos \theta_k \|\nabla F(w^{(k)})\| \|s^{(k)}\|$$

obtemos

$$F(w^{(k+1)}) \leq F(w^{(k)}) - c \cos^2 \theta_k \|\nabla F(w^{(k)})\|^2.$$

Esta desigualdade mostra que a função decresce pelo menos proporcional a $\cos^2 \theta_k \|\nabla f(w^{(k)})\|^2$ em cada iteração, o que será fundamental para concluir a convergência da soma usada no teorema de Zoutendijk.

Somando a desigualdade de decrescimento obtida sobre as iterações, temos

$$F(w^{(k+1)}) \leq F(w^{(0)}) - c \sum_{j=0}^k \cos^2 \theta_j \|\nabla F(w^{(j)})\|^2.$$

Como F é limitada inferiormente em $\mathcal{L}(w^{(0)})$, seja F^* um tal limite inferior. Então,

$$c \sum_{j=0}^k \cos^2 \theta_j \|\nabla f(w^{(j)})\|^2 \leq F(w^{(0)}) - F(w^{(k+1)}) \leq F(w^{(0)}) - F^*.$$

Portanto, a sucessão

$$\left\{ \sum_{j=0}^k \cos^2 \theta_j \|\nabla F(w^{(j)})\|^2 \right\}$$

é crescente e limitada superiormente, e, portanto é convergente.

Então, considerando $k \rightarrow \infty$, obtém-se o resultado do teorema de Zoutendijk:

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla F(w^{(k)})\|^2 < +\infty \quad (\text{série convergente}). \quad \square$$