Métodos de Procura Unidirecional de 1ª e 2ª ordem: Método de Descida Máxima, Método de Newton, Métodos Quasi-Newton

M. Fernanda P. Costa

Departamento de Matemática
Universidade do Minho

Outline

1. Método de Descida Máxima
   - Taxa de convergência do Método de Descida Máxima
2. Método de Newton
3. Métodos quasi-Newton
   - Método BFGS
   - Método SR1

Método de Descida Máxima

No *método de descida máxima* (ou *método do gradiente*), a direção de procura no ponto $w^{(k)}$ é a direção de *descida máxima*:

$$s^{(k)} = -\nabla F(w^{(k)}).$$

- A direção de descida máxima satisfaz a propriedade de descida:

$$s^{(k)\top}\nabla F(w^{(k)}) = -\nabla F(w^{(k)})^\top \nabla F(w^{(k)}) = -\|\nabla F(w^{(k)})\|^2 < 0.$$

- Entre todas as direções ao longo das quais F decresce, a direção oposta ao vetor gradiente é a de decrescimento mais acentuado. De facto, pela definição de produto interno entre dois vetores

$$s^{(k)\top}\nabla F(w^{(k)}) = \|s^{(k)}\|\|\nabla F(w^{(k)})\| \cos\theta$$

onde θ é o ângulo entre os vetores $s^{(k)}$ e $\nabla F(w^{(k)})$, e este termo tem o valor mínimo quando $\cos\theta = -1$, isto é, quando $\theta = \pi$, o que corresponde a $s^{(k)} = -\nabla F(w^{(k)})$.

O *método de descida máxima* é definido pelo seguinte algoritmo iterativo.

Algoritmo: Método de descida máxima

1. **Entrada**: F, $w^{(0)}$, tolerância $\varepsilon > 0$
2. Fazer $k = 0$
3. **Enquanto** ($\|\nabla F(w^{(k)})\|_\infty > \varepsilon$) **fazer**
4. Calcular a direção de descida máxima $s^{(k)} = -\nabla F(w^{(k)})$
5. Calcular o comprimento do passo:

$$\eta_k = Armijo(F, \nabla F(w^{(k)}), w^{(k)}, s^{(k)}) \text{ com Bactracking}$$

6. Fazer $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$
7. Fazer $k = k + 1$
8. **Fim enquanto**
9. **Saída:** $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)

Taxa de convergência do Método de Descida Máxima

Podemos aprender muito sobre o Método de Descida Máxima (MDM) considerando o caso ideal, no qual a função objetivo é quadrática e as procuras unidirecionais são exatas. Considere-se

$$F(w) = \frac{1}{2} w^T Q w - b^T w,$$

onde $Q_{q \times q}$ é simétrica e definida positiva (SDP), $b \in \mathbb{R}^d$. O gradiente é dado por $\nabla F(w) = Qw - b$, e o minimizante w^* é a única solução do sistema linear: $\nabla F(w) = 0$, ou seja, $Qw = b$.

Seja $w^{(k)}$ a aproximação atual do MDM, com

$$F(w^{(k)}) = \frac{1}{2} w^{(k)\,T} Q w^{(k)} - b^T w^{(k)}.$$

Agora calculemos a próxima iteração do MDM.
Temos de calcular o η_k que minimiza $F(w^{(k)} - \eta \nabla F_k)$:

$$\phi(\eta) = F(w^{(k)} - \eta \nabla F_k) = \frac{1}{2}(w^{(k)} - \eta \nabla F_k)^T Q (w^{(k)} - \eta \nabla F_k) - b^T (w^{(k)} - \eta \nabla F_k)$$

onde ∇F_k representa $\nabla F(w^{(k)})$.

Expandindo o termo quadrático,

$$
\begin{aligned}
\phi(\eta) =& \frac{1}{2} w^{(k)\,T} Q w^{(k)} - \eta \nabla F_k^T Q w^{(k)} + \frac{1}{2}\eta^2 \nabla F_k^T Q \nabla F_k - b^T w^{(k)} + \eta b^T \nabla F_k \\
=& \underbrace{\frac{1}{2} w^{(k)\,T} Q w^{(k)} - b^T w^{(k)}}_{F(w^{(k)})} - \eta \nabla F_k^T Q w^{(k)} + \frac{1}{2}\eta^2 \nabla F_k^T Q \nabla F_k + \eta (Q w^{(k)} - \nabla F_k)^T \nabla F_k \\
=& F(w^{(k)}) - \eta \nabla F_k^T Q w^{(k)} + \frac{1}{2}\eta^2 \nabla F_k^T Q \nabla F_k + \eta (Q w(k))^T \nabla F_k - \eta \nabla F_k^T \nabla F_k \\
=& F(w^{(k)}) + \frac{1}{2}\eta^2 \nabla F_k^T Q \nabla F_k) - \eta \nabla F_k^T \nabla F_k.
\end{aligned}
$$

Agora derivando em relação a η:

$$\phi'(\eta) = \eta \nabla F_k^T Q \nabla F_k - \nabla F_k^T \nabla F_k$$

Pela condição de otimalidade $\phi'(\eta) = 0$, obtemos o comprimento de passo ótimo:

$$\eta_k = \frac{\nabla F_k^T \nabla F_k}{\nabla F_k^T Q \nabla F_k}.$$

Portanto, a próxima iteração $w^{(k+1)}$ do algoritmo MDM será:

$$w^{(k+1)} = w^{(k)} - \eta_k \nabla F_k = w^{(k)} - \frac{\nabla F_k^T \nabla F_k}{\nabla F_k^T Q \nabla F_k} \nabla F_k \tag{1}$$

com

$$\begin{aligned} F(w^{(k+1)}) &= F(w^{(k)} - \eta \nabla F_k) \\ &= F(w^{(k)}) + \frac{1}{2}\eta^2 \nabla F_k^T Q \nabla F_k) - \eta \nabla F_k^T \nabla F_k \\ &= F(w^{(k)}) - \frac{1}{2} \frac{(\nabla F_k^T \nabla F_k)^2}{\nabla F_k^T Q \nabla F_k} \end{aligned}$$

Nota:

- Como $\nabla F_k = Qw^{(k)} - b$, a equação (1) produz uma expressão fechada para $w^{(k+1)}$ em termos de $w^{(k)}$.
- A Figura 1, mostra uma sucessão típica de iterados gerados pelo MDM aplicado a uma função quadrática bidimensional.
- Observe que os iterados apresentam um comportamento em ziguezague à medida que se aproximam da solução.
- Este ziguezague é uma forma não eficiente de aproximar-se do mínimo.

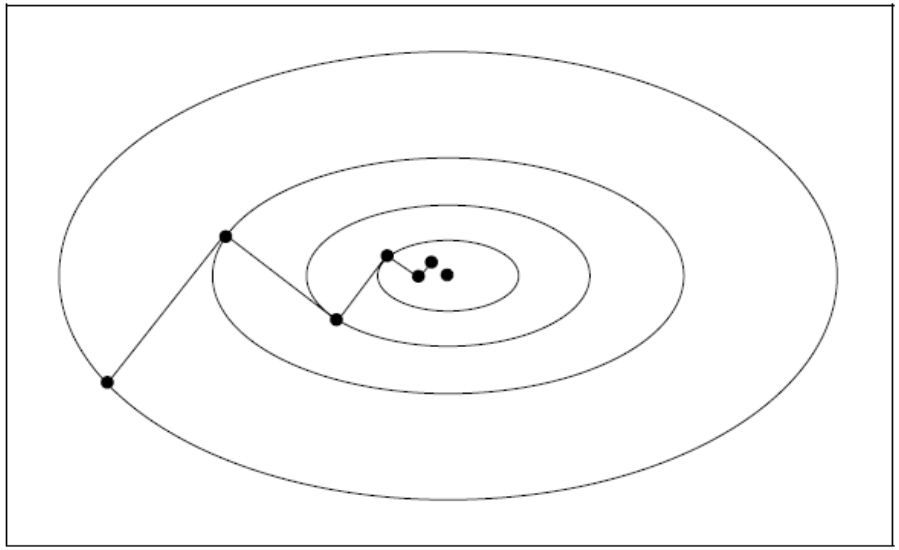

Figura 1: 7 iterações do MDM com procura exata, ao minimizar uma função quadrática convexa.

Teorema 1

Seja $F(w) = \frac{1}{2} w^T Q w - b^T w$, *onde* $Q_{d \times d}$ *é SSDP. Seja* $\{w^{(k)}\}$ *a sucessão de iterados obtido pelo MDM com procura undirecional exata, convergente para o minimizante global* w^* *de* F. *Então a sucessão* $\{F(w^{(k)})\}$ *converge linearmente para* $F(w^*)$ *com uma taxa de convergência*

$$r = \left(\frac{\lambda_d/\lambda_1 - 1}{\lambda_d/\lambda_1 + 1} \right)^2$$

onde $0 < \lambda_1 \leq \lambda_2 \leq \ldots \leq \lambda_d$ *são os valores próprios de* Q.

Nota:

- Observe que, por definição de λ_d e λ_1, λ_d/λ_1 é pelo menos 1. Se λ_d/λ_1 não for muito maior do 1 (pequeno) então a taxa de convergência r será muito menor que 1.
- Contudo, se λ_d/λ_1 for muito maior do 1 (grande), então a taxa de convergência r será ligeiramente menor que 1 e a velocidade de convergência será menor (i.e. será necessário um número maior de iterações até o MDM atingir a tolerância pretendida).

Síntese:

- Se F é limitada inferiormente, o método da *descida máxima*, com as condições de Wolfe (ou com procura exata, ou com a condição de Armijo com *backtracking*), é *globalmente convergente*.

- Contudo, apesar desta garantia teórica de convergência, o método pode revelar-se bastante ineficiente na prática.

- Vimos que, se $F(w)$ é uma função quadrática convexa, a sucessão $\{F(w^{(k)})\}$ obtida pelo método de descida máxima com procura exata *converge linearmente* para o mínimo global $F(w^*)$.

Método de Newton

Considere-se o problema de otimização sem restrições:

$$\underset{w \in \mathbb{R}^d}{\text{minimizar}} \; F(w)$$

onde $F : \mathbb{R}^d \to \mathbb{R}$ é duas vezes continuamente diferenciável.

Motivação:

- A ideia principal dos métodos de Newton baseia-se na observação de que, pelo menos localmente, uma função quadrática aproxima bem uma função não linear.
- Minimizar uma função quadrática é relativamente simples, pois a condição de primeira ordem conduz a um sistema linear de equações.

O método de Newton utiliza a expansão quadrática da série de Taylor de F em torno do ponto atual $w^{(k)}$:

$$F(w^{(k)} + s) \approx F(w^{(k)}) + s^\top \nabla F(w^{(k)}) + \frac{1}{2} s^\top \nabla^2 F(w^{(k)})\, s \overset{\text{def}}{=} m_k(s)$$

e dá um passo para o mínimo de $m_k(s)$.

Direção de Newton

Assumindo que a Hessiana $\nabla^2 F(w^{(k)})$ é definida positiva, podemos obter o minimizante da função quadrática $m_k(s)$ resolvendo o seguintes sistema linear:

$$\nabla m_k(w) = 0 \Leftrightarrow \nabla F(w^{(k)}) + \nabla^2 F(w^k)s = 0$$

donde se retira que o passo de Newton $s^{(k)}$ é a solução do sistema linear:

$$\nabla^2 F(w^{(k)})\, s^{(k)} = -\nabla F(w^{(k)}).$$

O método de Newton define então $w^{(k+1)} := w^{(k)} + s^{(k)}$ (ou possivelmente realiza uma procura unidirecional ao longo da direção $s^{(k)}$).

Note-se que teremos de ter cuidado se a matriz Hessiana $\nabla^2 F(w^{(k)})$, não for definida positiva.

Algoritmo do Método de Newton

O *método de Newton* é definido pelo seguinte algoritmo iterativo.

Algoritmo: Método de Newton

1. **Entrada**: F, $w^{(0)}$, tolerância $\varepsilon > 0$
2. Fazer $k = 0$
3. **Enquanto** ($\|\nabla F(w^{(k)})\|_\infty > \varepsilon$) **fazer**
4. Calcular a direção de Newton: $\nabla^2 F(w^{(k)})\, s^{(k)} = -\nabla F(w^{(k)})$
5. Calcular o comprimento do passo:

$$\eta_k = Armijo(F, \nabla F(w^{(k)}), w^{(k)}, s^{(k)}) \text{ com Bactracking}$$

6. Fazer $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$
7. Fazer $k = k + 1$
8. **Fim enquanto**
9. **Saída:** $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)

O lema seguinte mostra que a direção de Newton $s^{(k)}$ é uma direção de descida se a matriz Hessiana $\nabla^2 F(w^{(k)})$ for definida positiva.

Lema

Se $\nabla^2 F(w^{(k)})$ é definida positiva (DP), então a direção $s^{(k)}$ obtida da resolução do sistema $\nabla^2 F(w^{(k)})\, s^{(k)} = -\nabla F(w^{(k)})$, é uma direção de descida.

Demonstração: Dado que $\nabla^2 F(w^{(k)})$ é definida positiva, a sua inversa existe e também é definida positiva. Logo, a direção de Newton é

$$s^{(k)} = -\nabla^2 F(w^{(k)})^{-1} \nabla F(w^{(k)}).$$

Temos então

$$\nabla F(w^{(k)})^T s^{(k)} = \nabla F(w^{(k)})^T \big(-\nabla^2 F(w^{(k)})^{-1} \nabla F(w^{(k)}) \big) = -\nabla F(w^{(k)})^T \nabla^2 F(w^{(k)})^{-1} \nabla F(w^{(k)}) < 0,$$

pois $\nabla^2 F(w^{(k)})^{-1}$ é definida positiva. Portanto, $s^{(k)}$ é uma direção de descida.

FALTA ACABAR!!!

Métodos quasi-Newton

Método BFGS

Método SR1