

# Capítulo II: Variáveis Aleatórias Reais

Probabilidades e Aplicações

Licenciatura em Matemática  
Licenciatura em Ciências da Computação  
Universidade do Minho  
Ano Letivo 2025/2026

# 1. Definição e Exemplos. Considerações gerais.

É frequente estarmos interessados em associar aos resultados de uma experiência aleatória uma, ou mais, características numéricas.

Por exemplo, para a experiência aleatória que consiste em efetuar dois lançamentos consecutivos de um dado, podemos estar interessados em estudar:

- o número de faces par obtidas;
- a soma das faces obtidas;
- a diferença, em valor absoluto, entre as faces obtidas;
- etc...

# 1. Definição e Exemplos. Considerações gerais.

Se estivermos interessados em apenas uma característica numérica, matematicamente tal é formalizado através de uma função que a cada elemento do espaço amostral,  $\omega \in \Omega$ , faz corresponder um número real, i.e., uma função

$$\begin{aligned} X : \Omega &\rightarrow \mathbb{R} \\ \omega &\rightarrow X(\omega) \end{aligned}$$

em que  $\Omega$  é o espaço amostral da experiência aleatória.

# 1. Definição e Exemplos. Considerações gerais.

Exemplo:

Suponhamos que estamos interessados em estudar o número de faces par obtidas em dois lançamentos consecutivos do dado. Neste caso,

$$\Omega = \{(x_1, x_2) : x_i \in \{1, 2, 3, 4, 5, 6\}, i \in \{1, 2\}\}$$

e a função  $X$  é tal que:

$$\begin{aligned} X((1, 1)) &= X((1, 3)) = X((1, 5)) = X((3, 1)) = X((3, 3)) = X((3, 5)) = \\ &= X((5, 1)) = X((5, 3)) = X((5, 5)) = 0, \end{aligned}$$

$$\begin{aligned} X((2, 2)) &= X((2, 4)) = X((2, 6)) = X((4, 2)) = X((4, 4)) = X((4, 6)) = \\ &= X((6, 2)) = X((6, 4)) = X((6, 6)) = 2 \end{aligned}$$

e  $X(\omega) = 1$  para os restantes elementos de  $\Omega$ .

# 1. Definição e Exemplos. Considerações gerais.

Se quisermos estudar, em simultâneo,  $k$  características numéricas, com  $k \in \mathbb{N}$ , somos conduzidos a uma função  $k$ -dimensional

$$\begin{aligned}\mathbf{X}: \Omega &\rightarrow \mathbb{R}^k \\ \omega &\rightarrow (X_1(\omega), X_2(\omega), \dots, X_k(\omega)),\end{aligned}$$

com  $X_i : \Omega \rightarrow \mathbb{R}$  a  $i$ -ésima característica de interesse,  $i \in \{1, \dots, k\}$ .

Neste capítulo, iremos estudar apenas o caso unidimensional ( $k = 1$ ). O próximo capítulo será dedicado ao caso  $k \geq 2$ .

# 1. Definição e Exemplos. Considerações gerais.

Os **acontecimentos**, cujas probabilidades nos interessa calcular, são agora **expressos através de subconjuntos reais** que são elementos de  $\mathcal{B}(\mathbb{R})$ .

No exemplo em que a função  $X$  representa o número de faces par nos 2 lançamentos, o acontecimento “**não saiu qualquer face par**” é dado por:

$$\begin{aligned} X^{-1}(\{0\}) &= \{\omega \in \Omega : X(\omega) = 0\} \\ &= \{(1, 1), (1, 3), (1, 5), (3, 1), (3, 3), (3, 5), (5, 1), (5, 3), (5, 5)\}. \end{aligned}$$

E o acontecimento “**saiu pelo menos uma face par**” corresponde a

$$\begin{aligned} X^{-1}(\{1, 2\}) &= \{\omega \in \Omega : X(\omega) \in \{1, 2\}\} \\ &= \{(1, 2), (1, 4), (1, 6), (2, 1), (2, 2), (2, 3), (2, 4), (2, 5), (2, 6), \\ &\quad (3, 2), (3, 4), (3, 6), (4, 1), (4, 2), (4, 3), (4, 4), (4, 5), (4, 6), \\ &\quad (5, 2), (5, 4), (5, 6), (6, 1), (6, 2), (6, 3), (6, 4), (6, 5), (6, 6)\}. \end{aligned}$$

Note que, para **esta** função  $X$  particular, tem-se  $X^{-1}(\{1, 2\}) = X^{-1}([1, +\infty[)$ .

# 1. Definição e Exemplos. Considerações gerais.

Para simplificar a notação, os acontecimentos anteriores podem ser abreviados por “ $X = 0$ ” e “ $X \in \{1, 2\}$ ”, respetivamente, i.e.,

$$X^{-1}(\{0\}) \equiv (X = 0)$$

e

$$X^{-1}(\{1, 2\}) \equiv (X \in \{1, 2\})$$

Observe que na descrição destes dois acontecimentos foram usados subconjuntos reais que são elementos de  $\mathcal{B}(\mathbb{R})$ , nomeadamente:

- $\{0\}$  no primeiro caso;
- $\{1, 2\}$  no segundo caso.

No segundo caso, poderia ser usado também  $[1, +\infty[$ .

# 1. Definição e Exemplos. Considerações gerais.

De um modo geral, estaremos interessados em calcular probabilidades de acontecimentos da forma

$$X^{-1}(E) = \{\omega \in \Omega : X(\omega) \in E\} \equiv (X \in E),$$

em que  $E$  é um subconjunto real elemento de  $\mathcal{B}(\mathbb{R})$ .

Observe que é preciso garantir que estes acontecimentos pertencem a  $\mathcal{F}$ , a  $\sigma$ -álgebra sobre o espaço amostral  $\Omega$ , de modo a que a sua probabilidade esteja bem definida.

Assim, sendo  $(\Omega, \mathcal{F}, P)$  o espaço de probabilidade da experiência aleatória, a função  $X$  deverá ser tal que

$$\forall E \in \mathcal{B}(\mathbb{R}), X^{-1}(E) \in \mathcal{F},$$

de modo a que

$$P(X \in E) \equiv P(X^{-1}(E)) = P(\{\omega \in \Omega : X(\omega) \in E\})$$

esteja definida para todo o  $E \in \mathcal{B}(\mathbb{R})$ .



# 1. Definição e Exemplos. Considerações gerais.

## Definição [Variável aleatória real (v.a.r.)]

Sejam  $(\Omega, \mathcal{F}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma função.  $X$  diz-se uma variável aleatória real (v.a.r.) se

$$\forall E \in \mathcal{B}(\mathbb{R}), X^{-1}(E) \in \mathcal{F}.$$

É difícil provar, usando a definição, que uma dada função é uma v.a.r.. Na prática, usaremos resultados mais simples para verificar se uma função é, ou não é, uma v.a.r.. Em particular, o teorema seguinte será muito útil.

## Teorema

Sejam  $(\Omega, \mathcal{F}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma função.  $X$  é v.a.r. sse

$$\forall c \in \mathbb{R}, X^{-1}([-\infty, c]) \in \mathcal{F}.$$

[Demonstração] [Ver Lopes e Gonçalves, 2000]

# 1. Definição e Exemplos. Considerações gerais.

Exemplos: **1)** Considere a experiência aleatória que consiste em lançar uma moeda equilibrada. O espaço de probabilidade é  $(\Omega, \mathcal{P}(\Omega), P)$ , em que  $\Omega = \{cara, coroa\}$  e  $P$  é a medida de Laplace. **Usando o teorema anterior**, vamos provar que a função  $X : \Omega \rightarrow \mathbb{R}$  definida por

$$X(\omega) = \begin{cases} 1 & \text{se } \omega = cara \\ 0 & \text{se } \omega = coroa \end{cases}$$

é uma v.a.r..

Seja  $c \in \mathbb{R}$  qualquer. Tem-se,

$$X^{-1}(] - \infty, c]) = \begin{cases} \emptyset & \text{se } c < 0 \\ \{coroa\} & \text{se } 0 \leq c < 1 \\ \Omega & \text{se } c \geq 1 \end{cases}.$$

Uma vez que  $\emptyset \in \mathcal{P}(\Omega)$ ,  $\{coroa\} \in \mathcal{P}(\Omega)$  e  $\Omega \in \mathcal{P}(\Omega)$ , podemos afirmar que, qualquer que seja  $c \in \mathbb{R}$ ,  $X^{-1}(] - \infty, c]) \in \mathcal{P}(\Omega)$ , ficando assim provado que  $X$  é uma v.a.r..

Observe que o acontecimento “saiu uma cara” corresponde a  $X^{-1}(\{1\})$  (ou simplesmente “ $X = 1$ ”) e a sua probabilidade é

$$P(X = 1) \equiv P(X^{-1}(\{1\})) = P(\{cara\}) = \frac{1}{2}.$$

# 1. Definição e Exemplos. Considerações gerais.

Exemplos: **2)** Sejam  $(\Omega, \mathcal{F}, P)$  o espaço de probabilidade associado a uma experiência aleatória e  $B$  um acontecimento (i.e.,  $B \in \mathcal{F}$ ). Vamos provar que a função indicatriz do conjunto  $B$ , i.e., a função  $\mathbf{1}_B : \Omega \rightarrow \mathbb{R}$  definida por

$$\mathbf{1}_B(\omega) = \begin{cases} 1, & \text{se } \omega \in B \\ 0 & \text{se } \omega \in \bar{B} \end{cases},$$

é uma v.a.r..

Seja  $c \in \mathbb{R}$  qualquer. Tem-se,

$$\mathbf{1}_B^{-1}([-\infty, c]) = \begin{cases} \emptyset & \text{se } c < 0 \\ \bar{B} & \text{se } 0 \leq c < 1 \\ \Omega & \text{se } c \geq 1 \end{cases}.$$

Sendo  $\mathcal{F}$  uma  $\sigma$ -álgebra sobre  $\Omega$ , tem-se que  $\emptyset \in \mathcal{F}$ ,  $\bar{B} \in \mathcal{F}$  (porque  $B \in \mathcal{F}$ ) e  $\Omega \in \mathcal{F}$ , concluindo-se assim que, qualquer que seja  $c \in \mathbb{R}$ ,  $\mathbf{1}_B^{-1}([-\infty, c]) \in \mathcal{F}$ , e ficando assim provado que  $\mathbf{1}_B$  é uma v.a.r..

Note que, em palavras, o acontecimento “ $\mathbf{1}_B = 0$ ” corresponde a “na realização da experiência aleatória, não se obteve um elemento do conjunto  $B$ ” e tem-se

$$P(\mathbf{1}_B = 0) \equiv P(\mathbf{1}_B^{-1}(\{0\})) = P(\bar{B}) = 1 - P(B).$$

# 1. Definição e Exemplos. Considerações gerais.

## Definição [ $\sigma$ -álgebra gerada por uma v.a.r.]

Sejam  $(\Omega, \mathcal{F}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r.. Chamamos  $\sigma$ -álgebra gerada por  $X$  à seguinte família de subconjuntos de  $\Omega$

$$X^{-1}(\mathcal{B}(\mathbb{R})) = \{X^{-1}(B), B \in \mathcal{B}(\mathbb{R})\}.$$

Note que, pela definição de v.a.r., tem-se obviamente

$$X^{-1}(\mathcal{B}(\mathbb{R})) \subseteq \mathcal{F}.$$

# 1. Definição e Exemplos. Considerações gerais.

Na prática, muitas vezes temos que lidar com uma função de uma v.a.r.. A questão que se coloca é em que condições é que a composição de uma função, real de variável real, com uma v.a.r. resulta ainda numa v.a.r..

## Teorema

Sejam  $(\Omega, \mathcal{F}, P)$  um espaço de probabilidade,  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r. e  $\phi : D \subseteq \mathbb{R} \rightarrow \mathbb{R}$ . Se  $\phi$  é uma função contínua então  $\phi(X)$  também é uma v.a.r..

[Demonstração] [ver Lopes e Gonçalves, 2000]

Exemplos: Se  $X$  é uma v.a.r. então

- $X^2$  é uma v.a.r. (de uma forma geral,  $X^k$ , com  $k \in \mathbb{N}$ , é uma v.a.r.);
- $e^X$  é uma v.a.r.;
- $|X|$  é uma v.a.r.;
- se  $X > 0$ ,  $\log(X)$  é uma v.a.r..

## 2. Lei de probabilidade e função de distribuição.

Sejam  $(\Omega, \mathcal{F}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r..  
Tem-se o seguinte diagrama:

$$\begin{array}{ccccc} \Omega & & \xrightarrow{X} & & \mathbb{R} \\ & & & & \\ [0,1] & \xleftarrow{P} & X^{-1}(\mathcal{B}(\mathbb{R})) & \xleftarrow{X^{-1}} & \mathcal{B}(\mathbb{R}) \end{array}$$

**Definição [Lei de probabilidade de uma v.a.r.]**

A função  $P_X : \mathcal{B}(\mathbb{R}) \rightarrow [0, 1]$  definida por  $P_X = P \circ X^{-1}$ , ie,

$$P_X(B) = P(X^{-1}(B)) \equiv P(X \in B), \quad B \in \mathcal{B}(\mathbb{R}),$$

é designada de *lei de probabilidade* da v.a.r.  $X$ .

Observação:  $P_X$  é uma medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  [ver exercício da Folha Prática 4 para a demonstração].

## 2. Lei de probabilidade e função de distribuição.

### Definição [Função de distribuição de uma v.a.r.]

A função  $F_X : \mathbb{R} \rightarrow [0, 1]$  definida por: para  $c \in \mathbb{R}$ ,

$$F_X(c) = P_X([-\infty, c]) = P(X^{-1}([-\infty, c])) \equiv P(X \in [-\infty, c]) \equiv P(X \leq c),$$

é designada de *função de distribuição* da v.a.r.  $X$  ou *função de distribuição da lei de probabilidade*  $P_X$ .

### Observação: [V. IMP.]

Uma vez que  $\pi(\mathbb{R}) = \{[-\infty, c], c \in \mathbb{R}\}$  é um  $\pi$ -sistema sobre  $\mathbb{R}$  e é tal que  $\sigma(\pi(\mathbb{R})) = \mathcal{B}(\mathbb{R})$ , a lei de probabilidade  $P_X$  fica caracterizada pela respectiva função de distribuição  $F_X$  (recorde o Lema enunciado no final do Capítulo I). Assim, se uma outra v.a.r.  $Y$  tiver a mesma função de distribuição que  $X$  (i.e., se  $F_X = F_Y$ ), então a lei de probabilidade de  $Y$  coincide com a lei de probabilidade de  $X$ , ou seja, tem-se

$$\forall B \in \mathcal{B}(\mathbb{R}), P_X(B) = P_Y(B).$$

## 2. Lei de probabilidade e função de distribuição.

Exemplo: Voltemos à experiência que consiste em lançar uma moeda equilibrada. Já sabemos que o espaço de probabilidade é  $(\Omega, \mathcal{P}(\Omega), P)$ , com  $\Omega = \{cara, coroa\}$  e  $P$  a medida de probabilidade de Laplace.

A função de distribuição da v.a.r.  $X : \Omega \rightarrow \mathbb{R}$ , definida por  $X(cara) = 1$  e  $X(coroa) = 0$ , é dada por

$$\begin{aligned} c \in \mathbb{R}, F_X(c) &= P(X \leq c) \equiv P(X^{-1}([-\infty, c])) \\ &= \begin{cases} P(\emptyset) & \text{se } c < 0 \\ P(\{coroa\}) & \text{se } 0 \leq c < 1 \\ P(\Omega) & \text{se } c \geq 1 \end{cases} \\ &= \begin{cases} 0 & \text{se } c < 0 \\ \frac{1}{2} & \text{se } 0 \leq c < 1 \\ 1 & \text{se } c \geq 1 \end{cases} . \end{aligned}$$



## 2. Lei de probabilidade e função de distribuição.

Propriedades de uma função de distribuição:

Sejam  $(\Omega, \mathcal{F}, P)$  um espaço de probabilidade,  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r. e  $F$  a função de distribuição de  $X$ .  $F$  tem as seguintes propriedades:

- i)  $F$  é monótona não-decrescente;
- ii)  $\lim_{x \rightarrow -\infty} F(x) = 0$  e  $\lim_{x \rightarrow +\infty} F(x) = 1$ ;
- iii) para todo o  $a, b \in \mathbb{R}$ , com  $a < b$ , tem-se

$$P_X([a, b]) \equiv P(a < X \leq b) = F(b) - F(a)$$

em que  $P_X$  é a lei de probabilidade da v.a.r.  $X$ ;

- iv)  $F$  é contínua à direita;
- v)  $F$  é contínua em  $x_0 \in \mathbb{R}$  sse  $P_X(\{x_0\}) \equiv P(X = x_0) = 0$ ;
- vi)  $F$  tem, quando muito, uma infinidade numerável de pontos de descontinuidade.

[Demonstração de i) - iii)] Exercícios da Folha Prática 4 .

[Demonstração de vi)] Ver livro Lopes & Gonçalves, 2000.

## 2. Lei de probabilidade e função de distribuição.

Demonstração de iv): Pretende-se mostrar que, para todo o  $a \in \mathbb{R}$ ,

$$\lim_{c \rightarrow a^+} F(c) = F(a).$$

Como  $F$  é monótona e limitada, existe  $\lim_{c \rightarrow a^+} F(c)$ .

Vamos considerar uma sucessão  $(c_n)_{n \in \mathbb{N}} \searrow a$ , i.e., uma sucessão de números reais decrescente e convergente para  $a$ .

Observe que

$$\lim_{n \rightarrow +\infty} F(c_n) = \lim_{n \rightarrow +\infty} P_X([-\infty, c_n]) = P_X\left(\bigcap_{n \in \mathbb{N}} [-\infty, c_n]\right) = P_X([-\infty, a]) = F(a)$$

A segunda igualdade deve-se ao facto de  $([-\infty, c_n])_{n \in \mathbb{N}}$  ser uma sucessão decrescente de elementos de  $\mathcal{B}(\mathbb{R})$  e de  $P_X$  ser uma medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  (ver Propriedade VII) de uma medida de probabilidade).

Pela unicidade do limite, concluímos então que

$$\lim_{c \rightarrow a^+} F(c) = F(a).$$

## 2. Lei de probabilidade e função de distribuição.

Demonstração de v): Já sabemos que  $F$  é contínua à direita. Resta só provar que  $F$  é contínua à esquerda de  $x_0$  sse  $P_X(\{x_0\}) = 0$ . Observe que

$$\begin{aligned}P_X(\{x_0\}) &= P_X([-\infty, x_0]) - P_X([-\infty, x_0[)) \\&= F(x_0) - P_X\left(\bigcup_{n \in \mathbb{N}} \left[-\infty, x_0 - \frac{1}{n}\right]\right) \\&= F(x_0) - \lim_{n \rightarrow +\infty} P_X\left(\left[-\infty, x_0 - \frac{1}{n}\right]\right) \\&= F(x_0) - \lim_{n \rightarrow +\infty} F\left(x_0 - \frac{1}{n}\right) = F(x_0) - \lim_{c \rightarrow x_0^-} F(c)\end{aligned}$$

A terceira igualdade deve-se ao facto de  $\left([-\infty, x_0 - \frac{1}{n}]\right)_{n \in \mathbb{N}}$  ser uma sucessão crescente de elementos de  $\mathcal{B}(\mathbb{R})$  e  $P_X$  ser uma medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  (ver Prop. VI) de medida de probabilidade). Concluimos então que

$$P_X(\{x_0\}) = 0 \Leftrightarrow \lim_{c \rightarrow x_0^-} F(c) = F(x_0).$$

c.q.d.

## 3. Variáveis Aleatórias Reais Discretas

### 3.1 Definição. Função de Probabilidade.

No que se segue,  $(\Omega, \mathcal{F}, P)$  é um espaço de probabilidade,  $X : \Omega \rightarrow \mathbb{R}$  é uma v.a.r. e  $P_X$  representa a lei de probabilidade de  $X$ .

**Definição [v.a.r. discreta; lei de probabilidade discreta; contradomínio]**

Se existe um subconjunto real  $D \in \mathcal{B}(\mathbb{R})$  finito ou infinito numerável tal que  $P_X(D) \equiv P(X \in D) = 1$ , diz-se que  $X$  é uma v.a.r. discreta e que  $P_X$  é uma lei de probabilidade discreta.

Se  $X$  é uma v.a.r. discreta, ao menor subconjunto real  $D \in \mathcal{B}(\mathbb{R})$  que verifica a condição  $P_X(D) = 1$ , chama-se *contradomínio* ou *suporte* da v.a.r.  $X$  e denota-se por  $C_X$ .

## 3. Variáveis Aleatórias Reais Discretas

### 3.1 Definição. Função de Probabilidade.

No que se segue,  $(\Omega, \mathcal{F}, P)$  é um espaço de probabilidade,  $X : \Omega \rightarrow \mathbb{R}$  é uma v.a.r. e  $P_X$  representa a lei de probabilidade de  $X$ .

**Definição [v.a.r. discreta; lei de probabilidade discreta; contradomínio]**

Se existe um subconjunto real  $D \in \mathcal{B}(\mathbb{R})$  finito ou infinito numerável tal que  $P_X(D) \equiv P(X \in D) = 1$ , diz-se que  $X$  é uma v.a.r. discreta e que  $P_X$  é uma lei de probabilidade discreta.

Se  $X$  é uma v.a.r. discreta, ao menor subconjunto real  $D \in \mathcal{B}(\mathbb{R})$  que verifica a condição  $P_X(D) = 1$ , chama-se *contradomínio* ou *suporte* da v.a.r.  $X$  e denota-se por  $C_X$ .

#### Teorema

Se  $X$  é uma v.a.r. discreta ( $P_X$  é uma lei de probabilidade discreta) então o contradomínio de  $X$  é o conjunto de pontos de descontinuidade da respectiva função de distribuição.

[Demonstração] Ver livro de Lopes & Gonçalves

## 3.1 Definição. Função de Probabilidade.

### Teorema

Seja  $X$  uma v.a.r. discreta de contradomínio  $C_X$ . A lei de probabilidade  $P_X$  é caracterizada pela função  $f : \mathbb{R} \rightarrow [0, 1]$  definida por

$$f(a) = \begin{cases} P_X(\{a\}) \equiv P(X = a) & \text{se } a \in C_X \\ 0 & \text{se c.c.} \end{cases}.$$

$f$  é designada de *função de probabilidade da v.a.r.  $X$*  ou *função de probabilidade da lei  $P_X$* . Também é usual chamar *função massa de probabilidade de  $X/P_X$* .

[Demonstração] É evidente que, dada  $P_X$ , a função  $f$  fica completamente determinada. Suponhamos agora que  $f$  é conhecida e provemos que  $P_X$  também fica completamente definida. Ora, tem-se que,  $\forall E \in \mathcal{B}(\mathbb{R})$ ,

$$\begin{aligned} P_X(E) &= P_X(E \cap (C_X \cup \overline{C_X})) = \underbrace{P_X(E \cap C_X)}_{\text{numerável}} + \underbrace{P_X(E \cap \overline{C_X})}_{=0} \\ &= \sum_{x \in (E \cap C_X)} P_X(\{x\}) = \sum_{x \in (E \cap C_X)} f(x) \end{aligned} \quad \text{c.q.d.}$$

## 3.1 Definição. Função de Probabilidade.

### Observação:

Uma vez conhecida a função de probabilidade,  $f$ , da v.a.r.  $X$  de contra-domínio  $C_X = \{x_1, x_2, \dots, x_n, \dots\}$ , com  $x_1 < x_2 < \dots < x_n < \dots$ , a função de distribuição de  $X$  obtém-se do seguinte modo:

$$\begin{aligned} F_X(c) &= P_X([-\infty, c]) \equiv P(X \leq c) = \sum_{x_i \in C_X : x_i \leq c} f(x_i) \\ &= \begin{cases} 0 & \text{se } c < x_1 \\ f(x_1) & \text{se } x_1 \leq c < x_2 \\ f(x_1) + f(x_2) & \text{se } x_2 \leq c < x_3 \\ \vdots & \\ f(x_1) + f(x_2) + \dots + f(x_n) & \text{se } x_n \leq c < x_{n+1} \\ \vdots & \end{cases} \end{aligned}$$

## 3.1 Definição. Função de Probabilidade.

Observe ainda que, se  $X$  é uma v.a.r. discreta, de contradomínio  $C_X$  e função de probabilidade  $f$ , então:

- 1 qualquer que seja  $E \in \mathcal{B}(\mathbb{R})$ , tem-se

$$P_X(E) \equiv P(X \in E) = \sum_{a \in (C_X \cap E)} f(a),$$

como já foi visto na demonstração do último teorema e usado na construção da função de distribuição.

- 2 da definição de  $C_X$ , resulta obviamente que

$$\sum_{a \in C_X} f(a) = 1.$$



## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Nesta secção vamos estudar algumas leis de probabilidade discretas que são frequentemente utilizadas na prática.

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Nesta secção vamos estudar algumas leis de probabilidade discretas que são frequentemente utilizadas na prática.

### I) Lei Binomial com parâmetros $n$ e $p$ , com $n \in \mathbb{N}$ , $p \in ]0, 1[$

Seja  $(\Omega, \mathcal{F}, P)$  o espaço de probabilidade de uma experiência aleatória,  $\xi$ , e seja  $S$  um acontecimento que, numa realização de  $\xi$ , ocorre com probabilidade  $0 < p < 1$ , i.e.,  $S \in \mathcal{F}$  tal que  $P(S) = p$ .

Considere agora a v.a.r.  $X$  que representa o número de vezes que o acontecimento  $S$  ocorre em  $n$  repetições independentes de  $\xi$ .

Tem-se que  $X$  é uma v.a.r. discreta, de contradomínio  $C_X = \{0, 1, \dots, n\}$ , e com função de probabilidade  $f : \mathbb{R} \rightarrow [0, 1]$  dada por




$$f(k) = \begin{cases} \binom{n}{k} p^k (1-p)^{n-k} & \text{se } k \in \{0, 1, \dots, n\} \\ 0 & \text{se c.c.} \end{cases}.$$

Nestas condições, diz-se que a v.a.r.  $X$  segue a lei Binomial com parâmetros  $n$  e  $p$ , e abrevia-se por  $X \sim \text{Bin}(n, p)$ .

Nota: O acontecimento  $S$  é usualmente designado de "sucesso".

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

A título de exemplo, seguem-se três gráficos com a representação da função de probabilidade de algumas leis binomiais, todas com  $n = 10$  e  $p$  igual a 0.1, 0.5 e 0.7, respetivamente. É nítido o efeito que a variação de  $p$  provoca na assimetria da distribuição.



Nota: Atente também no efeito que a variação de  $p$  tem na localização e na variabilidade. Em particular, note que, para o mesmo valor de  $n$ , a variabilidade máxima é obtida quando  $p = 0.5$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### II) Lei de Bernoulli com parâmetro $p$ , com $p \in ]0, 1[$

Sejam  $(\Omega, \mathcal{F}, P)$  um espaço de probabilidade e  $A \in \mathcal{F}$  tal que  $P(A) = p$ , com  $0 < p < 1$ . Já vimos que a função  $X : \Omega \rightarrow \mathbb{R}$  definida por

$$X(w) = \begin{cases} 0 & \text{se } w \notin A \\ 1 & \text{se } w \in A \end{cases}$$

é uma v.a.r. e a sua lei de probabilidade,  $P_X$ , é tal que  $P_X(\{1\}) = p$  e  $P_X(\{0\}) = 1 - p$ . Como  $p \in ]0, 1[$ , temos que  $C_X = \{0, 1\}$ , pelo que  $X$  é uma v.a.r. discreta. A função de probabilidade de  $X$ ,  $f : \mathbb{R} \rightarrow [0, 1]$ , é dada por

$$f(k) = \begin{cases} p & \text{se } k = 1 \\ 1 - p & \text{se } k = 0 \\ 0 & \text{se } c.c. \end{cases}.$$

Nestas condições, diz-se que a v.a.r.  $X$  segue a lei de Bernoulli com parâmetro  $p$ , e abrevia-se por  $X \sim \text{Bernoulli}(p)$ .

Observação: A lei  $\text{Bernoulli}(p)$  coincide com a lei  $\text{Bin}(1, p)$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### III) Lei Hipergeométrica com parâmetros $R$ , $M$ e $n$

Suponha que numa caixa estão  $R$  elementos, dos quais  $0 \leq M \leq R$  possuem um certo atributo,  $A$ , e os restantes  $R - M$  elementos não têm este atributo  $A$ .

Considere agora a experiência aleatória que consiste em recolher uma amostra, sem reposição, de  $n$  elementos retirados da caixa e seja  $X$  a v.a.r. que representa o número de elementos da amostra que possuem o atributo  $A$ .

Tem-se que  $X$  é uma v.a.r. discreta, de contradomínio

$$C_X = \{\max(0, n - (R - M)), \dots, \min(n, M)\}$$

e função de probabilidade

$$f(k) = \begin{cases} \frac{\binom{M}{k} \binom{R-M}{n-k}}{\binom{R}{n}} & \text{se } k \in C_X \\ 0 & \text{se c.c.} \end{cases}.$$

Nestas condições, diz-se que a v.a.r.  $X$  segue a lei Hipergeométrica com parâmetros  $R$ ,  $M$  e  $n$ , e abrevia-se por  $X \sim HG(R, M, n)$ .

Nota: Se a amostra for feita com reposição, então  $X \sim \text{Bin}\left(n, \frac{M}{R}\right)$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Exemplo: Considere um lote de 10 peças, em que 4 são defeituosas e as restantes 6 não são defeituosas.

- Se escolhermos, ao acaso e sem reposição, 8 peças deste lote e considerarmos  $X$  a v.a.r. que representa o número de peças defeituosas entre as 8 escolhidas, temos que

$$X \sim HG(10, 4, 8)$$

e que  $C_X = \{2, 3, 4\}$ .

- Se escolhermos, ao acaso e com reposição, 8 peças deste lote e considerarmos  $Y$  a v.a.r. que representa o número de peças defeituosas entre as 8 escolhidas, temos que

$$Y \sim Bin\left(8, \frac{4}{10}\right)$$

e que  $C_Y = \{0, 1, 2, 3, 4, 5, 6, 7, 8\}$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### IV) Lei de Poisson com parâmetro $\lambda$ , com $\lambda \in \mathbb{R}^+$ :

Seja  $(X_n)_{n \in \mathbb{N}}$  uma sucessão de v.a.r.'s, todas definidas sobre o mesmo espaço de probabilidade  $(\Omega, \mathcal{A}, P)$ , e tais que  $X_n \sim \text{Bin}(n, p_n)$  com os parâmetros  $n$  e  $p_n$  a satisfazer

$$\lim_{n \rightarrow +\infty} p_n = 0 \text{ e } \lim_{n \rightarrow +\infty} np_n = \lambda,$$

com  $\lambda \in \mathbb{R}^+$ .

Nestas condições, tem-se que

$$\frac{P(X_n = k)}{P(X_n = k - 1)} = \frac{\binom{n}{k} p_n^k (1 - p_n)^{n-k}}{\binom{n}{k-1} p_n^{k-1} (1 - p_n)^{n-k+1}} = \frac{n - k + 1}{k} \frac{p_n}{1 - p_n} \xrightarrow{n \rightarrow +\infty} \frac{\lambda}{k}.$$

Isto permite-nos concluir que, para  $n$  suficientemente grande, a função de probabilidade da v.a.r.  $X_n$  comporta-se como a de uma v.a.r. discreta,  $Y$ , de contradomínio  $C_Y = \mathbb{N}_0$ , e tal que

$$P(Y = k) = \frac{\lambda}{k} P(Y = k - 1), \quad k \in \mathbb{N}.$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Trabalhando esta última igualdade, concluímos que

$$P(Y = k) = \frac{\lambda}{k} P(Y = k - 1) = \frac{\lambda^2}{k(k-1)} P(Y = k - 2) = \dots = \frac{\lambda^k}{k!} P(Y = 0).$$

Como  $C_Y = \mathbb{N}_0$ , temos

$$1 = \sum_{k=0}^{+\infty} P(Y = k) \Leftrightarrow 1 = \sum_{k=0}^{+\infty} \frac{\lambda^k}{k!} P(Y = 0) \Leftrightarrow 1 = P(Y = 0) e^{\lambda} \Leftrightarrow P(Y = 0) = e^{-\lambda}$$

Concluimos assim que, para todo o  $k \in \mathbb{N}_0$ ,  $P(Y = k) = \frac{\lambda^k}{k!} e^{-\lambda}$  e que a função de probabilidade de  $Y$  é dada por

$$f(k) = \begin{cases} \frac{\lambda^k}{k!} e^{-\lambda} & \text{se } k \in \mathbb{N}_0 \\ 0 & \text{se c.c.} \end{cases}.$$

Nestas condições, diz-se que  $Y$  segue a lei de Poisson com parâmetro  $\lambda$ , e abrevia-se por  $Y \sim \text{Poisson}(\lambda)$ .



## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### Nota:




A lei de Poisson é adequada para modelar o número de ocorrências de um fenómeno raro (i.e. um fenómeno que tem baixa probabilidade de ocorrer) quando não limitamos o número de repetições da experiência aleatória.

Em particular, a função de probabilidade da lei de Poisson é usada para obter um valor aproximado da função de probabilidade de uma v.a.r.

$Z \sim \text{Bin}(n, p)$  quando  $n$  é grande e  $p$  é pequeno. O parâmetro  $\lambda$  a utilizar na aproximação será igual a  $n \times p$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

A título de exemplo, seguem-se três gráficos com a representação da função de probabilidade de algumas leis de de Poisson, com  $\lambda$  igual a 0.5, 1 e 4, respetivamente. É nítido o efeito que a variação de  $\lambda$  tem na localização e na variabilidade.



## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### V) Lei Geométrica, com parâmetro $p$ , com $p \in ]0, 1[$ :

Considere uma experiência aleatória na qual um certo acontecimento, que designamos por “sucesso”, ocorre com probabilidade  $0 < p < 1$  (e ocorre “insucesso” com probabilidade  $1 - p$ ). Suponhamos agora que se repete esta experiência, sempre nas mesmas condições (i.e., as repetições são independentes) e seja  $T$  a v.a.r. que representa o número de vezes que se efetua a experiência até ocorrer “sucesso” pela primeira vez.

Naturalmente, tem-se que  $T$  é discreta e que  $C_T = \{1, 2, \dots\} = \mathbb{N}$ .

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Para determinar a função de probabilidade de  $T$ , considerem-se os seguintes acontecimentos:

$A_i$ : “ocorreu insucesso na  $i$ -ésima vez que se efetuou a experiência”,  
 $i = 1, 2, \dots$

Note-se que  $P(A_i) = 1 - p$  e  $P(\overline{A_i}) = p$ , para todo o  $i$ .

Usando estes acontecimentos (e observe que  $A_1, A_2, \dots, A_k$  formam uma família de  $k$  acontecimentos independentes) podemos facilmente obter alguns dos valores da função de probabilidade de  $T$ :

$$P(T = 1) = P(\overline{A_1}) = p;$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Para determinar a função de probabilidade de  $T$ , considerem-se os seguintes acontecimentos:

$A_i$ : “ocorreu insucesso na  $i$ -ésima vez que se efetuou a experiência”,  
 $i = 1, 2, \dots$

Note-se que  $P(A_i) = 1 - p$  e  $P(\overline{A_i}) = p$ , para todo o  $i$ .

Usando estes acontecimentos (e observe que  $A_1, A_2, \dots, A_k$  formam uma família de  $k$  acontecimentos independentes) podemos facilmente obter alguns dos valores da função de probabilidade de  $T$ :

$$P(T = 1) = P(\overline{A_1}) = p;$$

$$P(T = 2) = P(A_1 \cap \overline{A_2}) = P(A_1) \times P(\overline{A_2}) = (1 - p)p;$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Para determinar a função de probabilidade de  $T$ , considerem-se os seguintes acontecimentos:

$A_i$ : “ocorreu insucesso na  $i$ -ésima vez que se efetuou a experiência”,  
 $i = 1, 2, \dots$

Note-se que  $P(A_i) = 1 - p$  e  $P(\overline{A_i}) = p$ , para todo o  $i$ .

Usando estes acontecimentos (e observe que  $A_1, A_2, \dots, A_k$  formam uma família de  $k$  acontecimentos independentes) podemos facilmente obter alguns dos valores da função de probabilidade de  $T$ :

$$P(T = 1) = P(\overline{A_1}) = p;$$

$$P(T = 2) = P(A_1 \cap \overline{A_2}) = P(A_1) \times P(\overline{A_2}) = (1 - p)p;$$

$$P(T = 3) = P(A_1 \cap A_2 \cap \overline{A_3}) = P(A_1) \times P(A_2) \times P(\overline{A_3}) = (1 - p)^2 p;$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Para determinar a função de probabilidade de  $T$ , considerem-se os seguintes acontecimentos:

$A_i$ : “ocorreu insucesso na  $i$ -ésima vez que se efetuou a experiência”,  
 $i = 1, 2, \dots$

Note-se que  $P(A_i) = 1 - p$  e  $P(\overline{A_i}) = p$ , para todo o  $i$ .

Usando estes acontecimentos (e observe que  $A_1, A_2, \dots, A_k$  formam uma família de  $k$  acontecimentos independentes) podemos facilmente obter alguns dos valores da função de probabilidade de  $T$ :

$$P(T = 1) = P(\overline{A_1}) = p;$$

$$P(T = 2) = P(A_1 \cap \overline{A_2}) = P(A_1) \times P(\overline{A_2}) = (1 - p)p;$$

$$P(T = 3) = P(A_1 \cap A_2 \cap \overline{A_3}) = P(A_1) \times P(A_2) \times P(\overline{A_3}) = (1 - p)^2 p;$$

$$\vdots$$

$$P(T = k) = P(A_1 \cap A_2 \cap \dots \cap A_{k-1} \cap \overline{A_k}) = p(1 - p)^{k-1}, \quad k \in \mathbb{N}$$

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

Tem-se assim a seguinte definição:

### Definição

Sejam  $T$  uma v.a. discreta e  $p \in ]0, 1[$ .

Diz-se que  $T$  segue a *distribuição Geométrica com parâmetro  $p$* , e abrevia-se por  $T \sim \text{Geo}(p)$ , se o seu contradomínio é  $\mathbb{N}$  e a sua função de probabilidade é dada por

$$f(k) = \begin{cases} p(1-p)^{k-1} & \text{se } k \in \mathbb{N} \\ 0 & \text{se } c.c. \end{cases}$$

**Observações:** Se  $T \sim \text{Geo}(p)$ ,

1) Facilmente se verifica que, para todo o  $k \in \mathbb{N}$ ,

$$P(T > k) = (1-p)^k.$$

2)  $T$  tem a conhecida propriedade de falta de memória, i.e.,

$$P(T = k + n | T > k) = P(T = n),$$

para todo o  $k, n \in \mathbb{N}$ .



## 3.2 Leis de Probabilidade Discretas Mais Conhecidas




Exemplo/Exercício(TPC): Imagine um bêbado que tem  $n$  chaves na sua carteira e que, ao chegar a casa, não consegue identificar a única chave que abre a porta. Como está tão bêbado, de cada vez que ele tenta uma chave que não é a certa, não consegue colocá-la de lado pelo que na tentativa seguinte volta a ter  $n$  chaves disponíveis para a escolha. Calcule a probabilidade de ele:

- i) acertar à primeira;
- ii) acertar pela primeira vez na terceira tentativa;
- iii) errar as primeiras 5 tentativas;
- iv) acertar pela primeira vez na oitava tentativa, sabendo que errou nas primeiras 5.

Sugestão: Identificar uma v.a.r. relevante para o problema e que tenha distribuição Geométrica.

## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

A título de exemplo, seguem-se três gráficos com a representação da função de probabilidade de algumas leis Geométricas com  $p$  igual a 0.2, 0.5 e 0.8, respectivamente. É nítido o efeito que a variação de  $p$  tem na localização e na variabilidade.



## 3.2 Leis de Probabilidade Discretas Mais Conhecidas

### VI) Lei Uniforme num conjunto finito $U$ :

Seja  $U = \{u_1, u_2, \dots, u_n\}$  um subconjunto real finito, com  $n$  elementos. Diz-se que uma v.a.r.  $X$  segue a lei Uniforme no conjunto  $U$ , abrevia-se por  $X \sim \text{Uniforme}(U)$ , se a função de probabilidade é dada por

$$f(a) = \begin{cases} \frac{1}{n} & \text{se } a \in U \\ 0 & \text{se c.c.} \end{cases}.$$

Na prática, esta lei é utilizada sempre que se escolhe, ao acaso, um elemento do conjunto  $U$  e os diferentes elementos de  $U$  têm igual probabilidade de serem escolhidos.

# 4. Variáveis aleatórias reais (absolutamente) contínuas

## 4.1 Leis Difusas

### Definição [v.a.r./lei de probabilidade difusa]

Sejam  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidade e  $X : \Omega \rightarrow \mathbb{R}$  uma v.a.r..  $X$  diz-se difusa se a sua lei de probabilidade,  $P_X$ , for uma lei de probabilidade difusa sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , i.e., se  $P_X$  for tal que

$$P_X(\{a\}) \equiv P(X = a) = 0, \forall a \in \mathbb{R}.$$

### Notas:

- 1) Se  $X$  é uma v.a.r. difusa então a função de distribuição de  $X$ ,  $F_X$ , é uma função contínua. Ver propriedades da função de distribuição.
- 2) Se  $X$  é uma v.a.r. discreta então  $X$  não é difusa.

Entre as leis difusas, existe um subconjunto particularmente importante e que vamos estudar: o das leis de probabilidade absolutamente contínuas. Tais leis caracterizam-se à custa de uma função, real de variável real, chamada de *função densidade de probabilidade*.

## 4.2 Leis absolutamente contínuas

### Definição [Função densidade de probabilidade sobre $\mathbb{R}$ ]

Uma função  $f : \mathbb{R} \rightarrow \mathbb{R}$  diz-se uma função densidade de probabilidade sobre  $\mathbb{R}$  se:

- $f(x) \geq 0, \forall x \in \mathbb{R}$ ;
- $f$  é integrável e  $\int_{-\infty}^{+\infty} f(x)dx = 1$ .

Exemplos: Das funções indicadas no Exercício 5, da Folha Prática 1, quais as que são funções densidade de probabilidade?

## 4.2 Leis absolutamente contínuas

### Definição [Função densidade de probabilidade sobre $\mathbb{R}$ ]

Uma função  $f : \mathbb{R} \rightarrow \mathbb{R}$  diz-se uma função densidade de probabilidade sobre  $\mathbb{R}$  se:

- $f(x) \geq 0, \forall x \in \mathbb{R}$ ;
- $f$  é integrável e  $\int_{-\infty}^{+\infty} f(x)dx = 1$ .

Exemplos: Das funções indicadas no Exercício 5, da Folha Prática 1, quais as que são funções densidade de probabilidade?

- i), iv), v) e vi) são funções densidade de probabilidade;
- iii) não é uma função densidade de probabilidade porque não é integrável.
- ii), vii) e viii) não são funções densidade de probabilidade porque, apesar de integráveis, não satisfazem a condição  $\int_{-\infty}^{+\infty} f(x)dx = 1$ .

Nota: Recorde que todas estas funções são não-negativas.

## 4.2 Leis absolutamente contínuas

### Definição [v.a.r./lei de probabilidade absolutamente contínua]

Uma v.a.r.  $X$  diz-se absolutamente contínua se a sua lei de probabilidade,  $P_X$ , é uma lei absolutamente contínua sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , i.e., se existe uma função densidade de probabilidade sobre  $\mathbb{R}$ ,  $f$ , tal que

$$\forall_{a,b \in \mathbb{R}, a < b}, P_X(]a, b[) \equiv P(X \in ]a, b[) = \int_a^b f(x)dx.$$

À função  $f$  chamamos *função densidade de probabilidade da v.a.r.  $X$*  ou *função densidade de probabilidade da lei  $P_X$* .

Observação: É possível mostrar que toda a função densidade de probabilidade sobre  $\mathbb{R}$  determina uma única medida de probabilidade  $Q$  sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  absolutamente contínua que verifica a condição

$$\forall_{a,b \in \mathbb{R}, a < b}, Q(]a, b[) = \int_a^b f(x)dx.$$

## 4.2 Leis absolutamente contínuas

### Teorema

Se  $Q$  é uma lei de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  absolutamente contínua então  $Q$  é difusa.

[Demonstração]: Pretende-se provar que  $Q(\{a\}) = 0$ , para todo o  $a \in \mathbb{R}$ . Comece por observar que

$$\{a\} = \bigcap_{n \in \mathbb{N}} \left[ a - \frac{1}{n}, a + \frac{1}{n} \right].$$

Sendo  $Q$  absolutamente contínua então  $Q$  admite uma função densidade de probabilidade e seja  $f$  essa função. Tem-se, então, que

$$Q(\{a\}) = \lim_{n \rightarrow +\infty} Q\left(\left[ a - \frac{1}{n}, a + \frac{1}{n} \right]\right) = \lim_{n \rightarrow +\infty} \int_{a - \frac{1}{n}}^{a + \frac{1}{n}} f(x) dx = 0.$$

A primeira igualdade deve-se ao facto de  $Q$  ser uma medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  e a segunda deve-se ao facto de  $Q$  ser uma lei absolutamente contínua com função densidade de probabilidade  $f$ . c.q.d.



## 4.2 Leis absolutamente contínuas

Observação: Deste último teorema, resulta trivialmente que, se  $X$  é uma v.a.r. absolutamente contínua, então a respetiva lei,  $P_X$ , satisfaz as seguintes igualdades: para todo  $a, b \in \mathbb{R}$ ,  $a < b$ ,

$$P_X(]a, b[) = P_X([a, b[) = P_X(]a, b]) = P_X([a, b]) = \int_a^b f(x)dx,$$

i.e.,

$$P(X \in ]a, b[) = P(X \in [a, b[) = P(X \in ]a, b]) = P(X \in [a, b]) = \int_a^b f(x)dx,$$

i.e.,

$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b) = \int_a^b f(x)dx.$$

## 4.2 Leis absolutamente contínuas

Observação: Deste último teorema, resulta trivialmente que, se  $X$  é uma v.a.r. absolutamente contínua, então a respetiva lei,  $P_X$ , satisfaz as seguintes igualdades: para todo  $a, b \in \mathbb{R}$ ,  $a < b$ ,

$$P_X(]a, b[) = P_X([a, b[) = P_X(]a, b]) = P_X([a, b]) = \int_a^b f(x)dx,$$

i.e.,

$$P(X \in ]a, b[) = P(X \in [a, b[) = P(X \in ]a, b]) = P(X \in [a, b]) = \int_a^b f(x)dx,$$

i.e.,

$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b) = \int_a^b f(x)dx.$$

O teorema seguinte caracteriza as leis de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  que são absolutamente contínuas. Em particular, é estabelecida uma relação entre a função densidade de probabilidade e a função de distribuição de uma tal lei.

## 4.2 Leis absolutamente contínuas

### Teorema

Uma condição necessária e suficiente para que uma v.a.r.  $X$  seja absolutamente contínua é que a sua função de distribuição,  $F_X$ , verifique a seguinte condição

$$\forall c \in \mathbb{R}, F_X(c) = P_X([-\infty, c]) \equiv P(X \leq c) = \int_{-\infty}^c f(x)dx,$$

para alguma função densidade de probabilidade  $f$ .

[Demonstração]

( $\Rightarrow$ ) Suponhamos que  $X$  é uma v.a.r. absolutamente contínua. Então existe  $f$ , uma função densidade de probabilidade sobre  $\mathbb{R}$ , tal que

$$\forall a, b \in \mathbb{R} : a < b, P_X([a, b]) = \int_a^b f(x)dx.$$

## 4.2 Leis absolutamente contínuas

Então, para todo o  $c \in \mathbb{R}$ ,

$$\begin{aligned}F_X(c) &= P_X([-\infty, c]) = P_X([-\infty, c[) = P_X\left(\bigcup_{n \in \mathbb{N}} ]-n, c[ \right) \\&= \lim_{n \rightarrow +\infty} P_X(]-n, c[) \\&= \lim_{n \rightarrow +\infty} \int_{-n}^c f(x) dx \\&= \int_{-\infty}^c f(x) dx.\end{aligned}$$

Observe que a segunda igualdade deve-se ao facto de  $P_X$  ser uma lei difusa; a quarta igualdade deve-se a  $P_X$  ser medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  (Propriedade VI)); a penúltima igualdade deve-se a  $X$  ser absolutamente contínua com função densidade de probabilidade  $f$ ; a última igualdade deve-se ao facto de  $f$  ser integrável.

## 4.2 Leis absolutamente contínuas

( $\Leftarrow$ ) Suponhamos agora que  $X$  é uma v.a.r. cuja função de distribuição,  $F_X$ , é dada por

$$\forall c \in \mathbb{R}, \quad F_X(c) = \int_{-\infty}^c f(x)dx$$

para alguma função densidade de probabilidade  $f$ . Se provarmos que

$$\forall a, b \in \mathbb{R} : a < b, \quad P_X(]a, b[) = \int_a^b f(x)dx$$

fica demonstrado que  $X$  é uma v.a.r. absolutamente contínua. Para provar isto, basta mostrar as seguintes igualdades:

- a)  $P_X(]a, b]) = \int_a^b f(x)dx,$
- b)  $P_X(\{b\}) = 0.$

## 4.2 Leis absolutamente contínuas

Ora

$$P_X([a, b]) = F_X(b) - F_X(a) = \int_{-\infty}^b f(x)dx - \int_{-\infty}^a f(x)dx = \int_a^b f(x)dx,$$

ficando assim provado a). Observe que a primeira igualdade se deve a uma das propriedades de uma função de distribuição (propriedade iii)).  
Adicionalmente,

$$\begin{aligned} P_X(\{b\}) &= P_X\left(\bigcap_{n \in \mathbb{N}} \left]b - \frac{1}{n}, b + \frac{1}{n}\right]\right) \\ &= \lim_{n \rightarrow +\infty} P_X\left(\left]b - \frac{1}{n}, b + \frac{1}{n}\right]\right) \\ &= \lim_{n \rightarrow +\infty} \int_{b - \frac{1}{n}}^{b + \frac{1}{n}} f(x)dx \\ &= 0, \end{aligned}$$

e fica provado b). Observe que a segunda igualdade se deve ao facto de  $P_X$  ser medida de probabilidade sobre  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  (Propriedade VII)) e a penúltima igualdade faz uso de a). . c.q.d.